

Jev и LLM: где разница имеет значение

ДАННЫЕ	МОДЕЛИ	РЕЖИМ LLM	ЗАМЕРЫ
ANLI · ContractNLI · BANKING77	Jev 1.13 · DeepSeek V4.1 Flash · Qwen3.8 27B	Без reasoning · вероятности из logprobs	21–24 сентября 2026

Вокруг Jev поднялся шум: модель не пишет тексты, а сразу выбирает ответ и выдаёт вероятности. Но превращать языковую модель в классификатор умели и раньше. Можно ограничить ответ списком вариантов через structured output. А если нужны оценки классов — попросить один символ, например 0, 1 или 2, и взять logprobs этих токенов.

Отсюда наш вопрос: **что Jev даёт сверх этого приёма?** Быстрее обрабатывает текст? Лучше выбирает ответ? Выдаёт более надёжные вероятности? Мы сравнили её с DeepSeek и Qwen на публичных данных, чтобы отделить измеримые преимущества от новизны подачи. Ни хайп, ни знакомая идея сами по себе ещё не говорят, насколько полезен продукт.

Где мы ожидали увидеть разницу

- **Качество и удобство классификации.** Специализация Jev могла дать более точные ответы; отдельный API — упростить получение вероятностей по всем классам. LLM при этом может оказаться не хуже по качеству. [Сравнение на трёх задачах →](#)
- **Скорость на многих вопросах.** По документации Jev использует общий текст для независимой оценки вопросов. Но LLM тоже можно дать несколько вопросов за раз или отправлять запросы параллельно. Проверяем, остаётся ли преимущество Jev при обоих способах ускорения. [Замеры скорости →](#)
- **Меньше ложных тревог.** Полезные оценки должны помогать отделять нужные случаи от остальных. Сравниваем модели при одинаковой доле найденных противоречий, чтобы не путать качество с привычкой чаще отвечать «да». [Precision–recall →](#)
- **Вероятности, которым можно верить.** Если модель обещает 80%, событие должно встречаться примерно в 80% таких случаев. Проверяем, выполняется ли это лучше у Jev, чем у LLM с logprobs. [Калибровка →](#)

Это проверка готовых API. По ней можно судить о пользе Jev в наших задачах, но нельзя установить, насколько нова её внутренняя архитектура.

01 Чем отличаются и где лучше качество

Как устроено сравнение. Jev получает текст и набор вариантов, LLM – тот же текст и инструкцию вернуть код. В бинарном и трёхклассовом одиночном режиме LLM генерирует один токен; вероятность класса берём из logprobs и нормируем на сумму вероятностей допустимых кодов. У Jev используем probabilities.

СЦЕНАРИЙ	JEV	ОБЫЧНАЯ LLM
Один вопрос	Метка и полный вектор вариантов	Один токен и вероятности кодов из logprobs
Много вопросов к тексту	Общий state; независимая оценка вопросов по документации	Общий prompt; ответы генерируются последовательно
Много отдельных запросов	Можно отправлять одновременно	Тоже можно отправлять одновременно

TypeSafe документирует обработку общего state один раз и независимость вопросов. У авторегрессионной LLM следующие ответы условны на уже выданные токены; JSON Schema этого не меняет. Наши замеры проверяют результат и скорость API, но не раскрывают внутреннее устройство Jev. [Документация Jev](#).

Качество: macro-F1, выше лучше. Каждый класс имеет одинаковый вес. Jev выше на ANLI; Qwen выше на одиночных вопросах к договорам. На BANKING77 Jev и Qwen близки. Это наблюдения на выбранных поднаборах, не универсальный рейтинг.

ПУБЛИЧНЫЙ ПОДНАБОР	JEV 1.13	DEEPSEEK V4.1 FLASH	QWEN3.8 27B
ANLI · 300 · один вопрос	0.779	0.676	0.661
ContractNLI · 510 · один вопрос	0.734	0.689	0.760
ContractNLI · те же 510 · 17 вопросов	0.735	0.736	0.582
BANKING77 · 385 · 77 классов	0.773	0.654	0.769


ContractNLI проверяет выводы из договоров: подтверждение, противоречие или недостаток сведений. Q1 и Q17 используют одни и те же пары текст/утверждение. ANLI – короткие сложные выводы из текста, BANKING77 – выбор намерения обращения среди 77 вариантов. Это разные задачи; общего среднего рейтинга нет.

В Q17 обе LLM возвращают короткие коды без схемы, в BANKING77 код может состоять из нескольких токенов. Там сравниваем метки, а не полный вектор 77 вероятностей. У Jev этот вектор приходит сразу; у выбранных LLM top-20 его не покрывает. Choice допускает до 255 вариантов. [Контракт API](#).

Полнота Q17: Qwen вернула неверное число кодов в 9 из 30 вызовов; все 17 решений такого вызова считаются ошибками. У Jev и DeepSeek таких сбоев не было. Это ограничение проверенного формата коротких кодов, а не доказательство неспособности Qwen решить сами вопросы.

02 Два способа ускорить обработку

Одинаковая работа: 51 вопрос – 17 вопросов к каждому из трёх договоров. Слева объединяем вопросы в один вызов; справа отправляем одиночные вопросы параллельно. Точки – медиана трёх повторов, полоски – минимум и максимум. По оси Y время завершения всех запросов, без деления latency на число вопросов.



МОДЕЛЬ	ПО ОДНОМУ, ПОДРЯД · С	ПО 17 В ЗАПРОСЕ · С	ПО ОДНОМУ, 16 ОДНОВРЕМЕННО · С	СТОИМОСТЬ 1000 РЕШЕНИЙ · Q17
Jev 1.13	7.75	0.73	1.12	\$0.014
DeepSeek V4.1 Flash	12.01	1.68	4.47 †	\$0.026
Qwen3.8 27B	25.85	3.28 †	5.46	\$0.031

Это два разных способа ускорения. Несколько вопросов в одном вызове убирают повторную передачу контекста. Отдельные запросы можно обрабатывать одновременно, но контекст передаётся повторно; его вычисления провайдер иногда переиспользует через cache. Такой параллелизм доступен всем трём API. Нельзя сравнивать многовопросный Jev только с последовательными вызовами LLM и весь выигрыш приписывать модели.

Стоимость рассчитана по сохранённому usage.

Что измерено: полное время API с одного сервера в США, IP 107.172.73.82; SSH исключён. Сеть, очереди, cache и обработку у провайдера полностью не разделить. Первые соединения включены. У LLM здесь выдача меток без logprobs и без схемы; у Jev вероятности входят в ответ. Скорость возврата полного массива вероятностей у LLM этим опытом не измеряется.


† Полнота Q17 в скоростном контроле: Jev 1.13 – 9/9 ответов в корректном формате; DeepSeek V4.1 Flash – 9/9 ответов в корректном формате; Qwen3.8 27B – 8/9 ответов в корректном формате. График учитывает и неполные ответы; качество решения вопросов сравнивается отдельно в таблице macro-F1.

Ошибки API включены: Jev 1.13 0/513; DeepSeek V4.1 Flash 4/513; Qwen3.8 27B 0/513. Используем первый проход каждого блока; повтор после 503 сохранён только как диагностика. Сбой снижает полноту и качество, его задержка остаётся в замере.

03 Меньше ложных тревог при нужном recall

Задача — найти противоречие в договоре. 510 пар текст/утверждение, из них 48 противоречий (9.4%). Исходная бинарная формулировка, одинаковая для всех моделей. Подтверждённое и неизвестное утверждение относятся к классу «нет противоречия».

Recall: сколько настоящих противоречий нашли. **Precision:** какая доля тревог верна. Каждый порог даёт свою точку на кривой. При нужном recall выбираем кривую выше: она даёт меньше ложных тревог.



МОДЕЛЬ	AVERAGE PRECISION ↑	PRECISION ПРИ R ≥ 80%	ВЕРНЫЕ / ЛОЖНЫЕ ТРЕВОГИ
Jev 1.13	0.713	48.1%	39 / 42
DeepSeek V4.1 Flash	0.677	50.0%	39 / 39
Qwen3.8 27B	0.660	40.6%	39 / 57


Во всех трёх точках найдены **39 из 48 противоречий — recall 81.25%**, ближайший достижимый шаг к цели 80%. Сравниваем целые случаи без интерполяции. Это описательный срез тестовой выборки.

Average Precision (AP) суммирует качество по всей PR-кривой. Полезна для общего ранжирования, но не заменяет точку под вашу задачу. У Jev и DeepSeek около выбранного recall примерно половина тревог ложная: удобный API сам по себе не решает проблему качества.

Неопределённость сравнения: DeepSeek V4.1 Flash - Jev: +1.9 п.п., 95% интервал [-13.2; +14.3]. Qwen3.8 27B - Jev: -7.5 п.п., 95% интервал [-20.9; +13.7]. Интервалы пересэмплируют целые договоры; если интервал включает ноль, преимущество в этой точке не установлено.

04 Можно ли верить вероятностям

Большое число ещё не означает надёжную вероятность. Если модель выдаёт 0.8, среди многих подобных случаев противоречие должно встречаться примерно в 80%. Это проверяет следующий график. Диагональ — идеальное совпадение; ниже диагонали модель завышает вероятность противоречия. Числа у точек — размер группы.



Пример из самой уверенной группы, $p \geq 90\%$: Jev 1.13 — $97.7\% \rightarrow 65.9\%$, 44 примеров; DeepSeek V4.1 Flash — $99.3\% \rightarrow 57.1\%$, 49 примеров. У этих двух моделей такая уверенность заметно завышена. У Qwen в этом диапазоне всего один пример — судить по нему нельзя.

МОДЕЛЬ	BRIER ↓	ECE ↓
Jev 1.13	0.081	8.8 п.п.
DeepSeek V4.1 Flash	0.075	7.3 п.п.
Qwen3.8 27B	0.050	1.6 п.п.

Qwen здесь лучше по Brier и ECE, хотя хуже ранжирует случаи по AP. Это разные свойства: модель может аккуратнее оценивать вероятность, но давать больше ложных тревог при требуемом recall. Вывод относится к этой выборке.

Brier — среднее $(p - y)^2$, где $y=1$, если противоречие есть. Для $p=0.8$ ошибка равна 0.04 на положительном случае и 0.64 на отрицательном. На этой выборке постоянный прогноз частоты 9.4% даёт Brier 0.085 — полезный ориентир при дисбалансе.

ECE — средний разрыв между обещанной вероятностью и реальной частотой, с весом числа примеров в каждой из десяти групп. Меньше — лучше, но редкие группы шумные. Маленький ECE не заменяет хорошую PR-кривую: постоянный прогноз частоты не умеет различать примеры.

У Jev отдельное поле `confidence` описывает концентрацию распределения; мы проверяем именно `probabilities`, а у LLM — нормированные `logprobs`. В графике и таблице только исходные числа, без посткалибровки. Что означает confidence.

05 Что выяснили — и чего не доказали

Где преимущество Jev видно

Скорость — самый ясный результат. Jev была быстрее в каждом проверенном режиме. При 17 вопросах за вызов весь набор из 51 вопроса занял 0.73 с против 1.68 с у DeepSeek и 3.28 с у Qwen. Это время API, а не чистое время вычислений модели; у Qwen один из девяти ответов в этом скоростном режиме был неполным.

Удобство API тоже отличается. Jev сразу возвращает вероятности всех 77 вариантов в нашей задаче BANKING77. Выбранные LLM с top-20 logprobs такого полного вектора не дают. Несколько вопросов к тексту у Jev — штатный режим; у LLM в нашем формате коротких кодов приходится ещё проверять полноту ответа.

Где общего превосходства нет

По качеству всё зависит от задачи. Jev выше на ANLI: macro-F1 0.779 против 0.676 и 0.661. На одиночных вопросах к договорам выше Qwen: 0.760 против 0.734 у Jev. На BANKING77 Jev и Qwen близки, а при 17 вопросах к договору близки Jev и DeepSeek.

Вероятности Jev не оказались автоматически лучше. У Jev выше Average Precision по всей PR-кривой, но при одинаковом recall 81.25% её precision — 48.1%, у DeepSeek — 50.0%, у Qwen — 40.6%.

Неопределённость слишком велика, чтобы установить победителя в этой точке. По совпадению вероятностей с реальной частотой лучше Qwen: у неё ниже и Brier, и ECE. Уверенные ответы Jev заметно переоценены.

Что можно сказать про новизну

Классификация с вероятностями сама по себе не новая возможность: наш вариант «LLM + logprobs» работает. Но свести Jev к одному маркетингу тоже нельзя: в этих замерах есть выигрыш по скорости и удобству выдачи полного набора вероятностей. Мы не доказали ни принципиально новую архитектуру, ни универсальное превосходство Jev. Практический выбор — по своей задаче: скорость и удобство отдельно, точность и надёжность вероятностей отдельно.

Границы опыта. Публичные поднаборы англоязычные и могли попадать в предобучение. Оценка бинарных вероятностей относится к ContractNLI, а не ко всем задачам. Всего 30 договоров и 48 противоречий; разметку не меняли под ответы моделей. Qwen измерена 24 сентября, прежнее качество Jev/DeepSeek — 21–22 сентября; новые скоростные режимы все выполнены 24 сентября. DeepSeek закреплён за Together, Qwen за Parasail через OpenRouter; это сравнение доступных API-маршрутов, не одинакового железа.

Полные метрики и score · Таблица качества CSV · Протокол · Проверка сырых ответов. Данные: ANLI, ContractNLI, BANKING77. Модель и маршрут: Qwen3.8 27B, DeepSeek V4.1 Flash.