

Jev и LLM: где разница имеет значение

ДАННЫЕ	МОДЕЛИ	РЕЖИМ LLM	ЗАМЕРЫ
ANLI · ContractNLI · BANKING77	Jev 1.13 · DeepSeek V4.1 Flash · Qwen3.8 27B	Без reasoning · вероятности из logprobs	21–24 сентября 2026

Обычная LLM с одним токеном ответа и logprobs уже умеет классифицировать и выдавать вероятности. У Jev стоит искать выигрыш в качестве на конкретной задаче, времени обработки многих вопросов и удобстве полного вектора вероятностей. Ни одно из этих преимуществ не следует из названия «System One».

01 Чем отличаются и где лучше качество

Как устроено сравнение. Jev получает текст и набор вариантов, LLM — тот же текст и инструкцию вернуть код. В бинарном и трёхклассовом одиночном режиме LLM генерирует один токен; вероятность класса берём из logprobs и нормируем на сумму вероятностей допустимых кодов. У Jev используем probabilities.

СЦЕНАРИЙ	JEV	ОБЫЧНАЯ LLM
Один вопрос	Метка и полный вектор вариантов	Один токен и вероятности кодов из logprobs
Много вопросов к тексту	Общий state; независимая оценка вопросов по документации	Общий prompt; ответы генерируются последовательно
Много отдельных запросов	Можно отправлять одновременно	Тоже можно отправлять одновременно

TypeSafe документирует обработку общего state один раз и независимость вопросов. У авторегрессионной LLM следующие ответы условны на уже выданные токены; JSON Schema этого не меняет. Наши замеры проверяют результат и скорость API, но не раскрывают внутреннее устройство Jev. [Документация Jev](#).

Качество: макро-F1, выше лучше. Каждый класс имеет одинаковый вес. Jev выше на ANLI; Qwen выше на одиночных вопросах к договорам. На BANKING77 Jev и Qwen близки. Это наблюдения на выбранных поднаборах, не универсальный рейтинг.

ПУБЛИЧНЫЙ ПОДНАБОР	JEV 1.13	DEEPSEEK V4.1 FLASH	QWEN3.8 27B
ANLI · 300 · один вопрос	0.779	0.676	0.661
ContractNLI · 510 · один вопрос	0.734	0.689	0.760
ContractNLI · те же 510 · 17 вопросов	0.735	0.736	0.582
BANKING77 · 385 · 77 классов	0.773	0.654	0.769


ContractNLI проверяет выводы из договоров: подтверждение, противоречие или недостаток сведений. Q1 и Q17 используют одни и те же пары текст/утверждение. ANLI — короткие сложные выводы из текста, BANKING77 — выбор намерения обращения среди 77 вариантов. Это разные задачи; общего среднего рейтинга нет.

В Q17 обе LLM возвращают короткие коды без схемы, в BANKING77 код может состоять из нескольких токенов. Там сравниваем метки, а не полный вектор 77 вероятностей. У Jev этот вектор приходит сразу; у выбранных LLM top-20 его не покрывает. Choice допускает до 255 вариантов. [Контракт API](#).

Полнота Q17: Qwen вернула неверное число кодов в 9 из 30 вызовов; все 17 решений такого вызова считаются ошибками. У Jev и DeepSeek таких сбоев не было. Это ограничение проверенного формата коротких кодов, а не доказательство неспособности Qwen решить сами вопросы.

02 Два способа ускорить обработку

Одинаковая работа: 51 вопрос – 17 вопросов к каждому из трёх договоров. Слева объединяем вопросы в один вызов; справа отправляем одиночные вопросы параллельно. Точки – медиана трёх повторов, полоски – минимум и максимум. По оси Y время завершения всех запросов, без деления latency на число вопросов.



МОДЕЛЬ	ПО ОДНОМУ, ПОДРЯД · С	ПО 17 В ЗАПРОСЕ · С	ПО ОДНОМУ, 16 ОДНОВРЕМЕННО · С	СТОИМОСТЬ 1000 РЕШЕНИЙ · Q17
Jev 1.13	7.75	0.73	1.12	\$0.014
DeepSeek V4.1 Flash	12.01	1.68	4.47 †	\$0.026
Qwen3.8 27B	25.85	3.28 †	5.46	\$0.031

Это два разных способа ускорения. Несколько вопросов в одном вызове убирают повторную передачу контекста. Отдельные запросы можно обрабатывать одновременно, но контекст передаётся повторно; его вычисления провайдер иногда переиспользует через cache. Такой параллелизм доступен всем трём API. Нельзя сравнивать многовопросный Jev только с последовательными вызовами LLM и весь выигрыш приписывать модели.

Стоимость рассчитана по сохранённому usage.

Что измерено: полное время API с одного сервера в США, IP 107.172.73.82; SSH исключён. Сеть, очереди, cache и обработку у провайдера полностью не разделить. Первые соединения включены. У LLM здесь выдача меток без logprobs и без схемы; у Jev вероятности входят в ответ. Скорость возврата полного массива вероятностей у LLM этим опытом не измеряется.


† Полнота Q17 в скоростном контроле: Jev 1.13 – 9/9 ответов в корректном формате; DeepSeek V4.1 Flash – 9/9 ответов в корректном формате; Qwen3.8 27B – 8/9 ответов в корректном формате. График учитывает и неполные ответы; качество решения вопросов сравнивается отдельно в таблице macro-F1.

Ошибки API включены: Jev 1.13 0/513; DeepSeek V4.1 Flash 4/513; Qwen3.8 27B 0/513. Используем первый проход каждого блока; повтор после 503 сохранён только как диагностика. Сбой снижает полноту и качество, его задержка остаётся в замере.

03 Меньше ложных тревог при нужном recall

Задача — найти противоречие в договоре. 510 пар текст/утверждение, из них 48 противоречий (9.4%). Исходная бинарная формулировка, одинаковая для всех моделей. Подтверждённое и неизвестное утверждение относятся к классу «нет противоречия».

Recall: сколько настоящих противоречий нашли. **Precision:** какая доля тревог верна. Каждый порог даёт свою точку на кривой. При нужном recall выбираем кривую выше: она даёт меньше ложных тревог.



МОДЕЛЬ	AVERAGE PRECISION ↑	PRECISION ПРИ R ≥ 80%	ВЕРНЫЕ / ЛОЖНЫЕ ТРЕВОГИ
Jev 1.13	0.713	48.1%	39 / 42
DeepSeek V4.1 Flash	0.677	50.0%	39 / 39
Qwen3.8 27B	0.660	40.6%	39 / 57


Во всех трёх точках найдены **39 из 48 противоречий — recall 81.25%**, ближайший достижимый шаг к цели 80%. Сравниваем целые случаи без интерполяции. Это описательный срез тестовой выборки.

Average Precision (AP) суммирует качество по всей PR-кривой. Полезна для общего ранжирования, но не заменяет точку под вашу задачу. У Jev и DeepSeek около выбранного recall примерно половина тревог ложная: удобный API сам по себе не решает проблему качества.

Неопределённость сравнения: DeepSeek V4.1 Flash - Jev: +1.9 п.п., 95% интервал [-13.2; +14.3]. Qwen3.8 27B - Jev: -7.5 п.п., 95% интервал [-20.9; +13.7]. Интервалы пересэмплируют целые договоры; если интервал включает ноль, преимущество в этой точке не установлено.

04 Можно ли верить вероятностям

Большое число ещё не означает надёжную вероятность. Если модель выдаёт 0.8, среди многих подобных случаев противоречие должно встречаться примерно в 80%. Это проверяет следующий график. Диагональ — идеальное совпадение; ниже диагонали модель завышает вероятность противоречия. Числа у точек — размер группы.



Пример из самой уверенной группы, $p \geq 90\%$: Jev 1.13 — $97.7\% \rightarrow 65.9\%$, 44 примеров; DeepSeek V4.1 Flash — $99.3\% \rightarrow 57.1\%$, 49 примеров. У этих двух моделей такая уверенность заметно завышена. У Qwen в этом диапазоне всего один пример — судить по нему нельзя.

МОДЕЛЬ	BRIER ↓	ECE ↓
Jev 1.13	0.081	8.8 п.п.
DeepSeek V4.1 Flash	0.075	7.3 п.п.
Qwen3.8 27B	0.050	1.6 п.п.

Qwen здесь лучше по Brier и ECE, хотя хуже ранжирует случаи по AP. Это разные свойства: модель может аккуратнее оценивать вероятность, но давать больше ложных тревог при требуемом recall. Вывод относится к этой выборке.

Brier — среднее $(p - y)^2$, где $y=1$, если противоречие есть. Для $p=0.8$ ошибка равна 0.04 на положительном случае и 0.64 на отрицательном. На этой выборке постоянный прогноз частоты 9.4% даёт Brier 0.085 — полезный ориентир при дисбалансе.

ECE — средний разрыв между обещанной вероятностью и реальной частотой, с весом числа примеров в каждой из десяти групп. Меньше — лучше, но редкие группы шумные. Маленький ECE не заменяет хорошую PR-кривую: постоянный прогноз частоты не умеет различать примеры.

У Jev отдельное поле `confidence` описывает концентрацию распределения; мы проверяем именно `probabilities`, а у LLM — нормированные `logprobs`. В графике и таблице только исходные числа, без посткалибровки. Что означает confidence.

05 Что это означает для выбора

Как читать итог. Для одного вопроса с несколькими вариантами приём «один токен + logprobs» работает. Jev удобнее, когда нужен полный вектор по многим классам или много вопросов к общему тексту. Выбирать по скорости нужно между лучшими допустимыми способами вызова, а вероятность проверять на своей задаче: формат числа её точности не гарантирует.

Границы опыта. Публичные поднаборы англоязычные и могли попадать в предобучение. Оценка бинарных вероятностей относится к ContractNLI, а не ко всем задачам. Всего 30 договоров и 48 противоречий; разметку не меняли под ответы моделей. Qwen измерена 24 сентября, прежнее качество Jev/DeepSeek – 21–22 сентября; новые скоростные режимы все выполнены 24 сентября. DeepSeek закреплён за Together, Qwen за Parasail через OpenRouter; это сравнение доступных API-маршрутов, не одинакового железа.

Полные метрики и score · Таблица качества CSV · Протокол · Проверка сырых ответов. Данные: ANLI, ContractNLI, BANKING77. Модель и маршрут: Qwen3.8 27B, DeepSeek V4.1 Flash.