

Jev и LLM: где разница имеет значение

ДАННЫЕ	МОДЕЛИ	РЕЖИМ LLM	ЗАМЕРЫ
ANLI · ContractNLI · BANKING77	Jev 1.13 · DeepSeek V4.1 Flash · Qwen3.8 27B	Без reasoning · вероятности из logprobs	21–24 сентября 2026

Вокруг Jev поднялся шум: модель не пишет тексты, а сразу выбирает вариант ответа и выдаёт вероятности. Но превращать языковую модель в классификатор умели и раньше: попросить один символ вместо ответа, например 0, 1 или 2, и взять logprobs этих токенов. Получится и метка, и оценка каждого класса.

Отсюда наш вопрос: **что Jev даёт сверх этого приёма?** Быстрее обрабатывает текст? Точнее выбирает ответ? Выдаёт вероятности, которым можно верить? Мы сравнили её с двумя обычными LLM на публичных данных, чтобы отделить измеримые преимущества от новизны подачи.

Это проверка готовых API, а не архитектуры. По ней можно судить о пользе Jev в похожих задачах, но нельзя установить, что у неё внутри.

Кого и как сравнивали

Jev — модель компании TypeSafe. Её API принимает текст и вопрос с набором вариантов (до 255), а возвращает выбранный вариант и вероятности по всем вариантам сразу. К одному тексту можно задать несколько вопросов в одном вызове: по документации текст обрабатывается один раз, а вопросы оцениваются независимо. Мы проверяем результат и скорость этого API, но не его устройство.

[Документация Jev](#) · [Контракт API](#).

LLM — DeepSeek V4.1 Flash и Qwen3.8 27B. Критерий выбора простой: доступные быстрые и недорогие API с рабочими logprobs и отключаемым reasoning. Мы не пытались выбрать самые точные LLM и не подбирали паритет по цене, размеру или железу, поэтому результат нельзя обобщать на все языковые модели.

DeepSeek закреплён за Together, Qwen за Parasail через OpenRouter; Jev — родной API TypeSafe. [Qwen3.8 27B](#) · [DeepSeek V4.1 Flash](#).

Baseline для LLM. Тот же текст и инструкция вернуть короткий код класса, без JSON Schema. Режимы отличаются. В бинарных и трёхклассовых одиночных опытах LLM генерирует один токен, и вероятность класса — это $\exp(\logprob)$ его кода, нормированная на сумму вероятностей допустимых кодов. На BANKING77 код класса может состоять из нескольких токенов, и там сравниваем только метку. На 17 вопросов к одному тексту LLM возвращает 17 кодов подряд. В скоростном опыте LLM отдаёт короткий код без logprobs даже на одиночный вопрос. У Jev берём поле `probabilities`.

Данные. ANLI — 300 коротких, но сложных выводов из текста: три класса. ContractNLI — 30 договоров, к каждому 17 утверждений, всего 510 пар текст/утверждение: подтверждено, противоречит, сведений недостаточно. BANKING77 — 385 обращений в банк, по 5 на каждое из 77 намерений. Все три набора публичные и англоязычные.

Четыре проверки

- **Качество выбора метки.** Три задачи, macro-F1. Специализация Jev могла дать более точные ответы, но LLM могли оказаться не хуже. → [01](#)
- **Скорость на многих вопросах.** Jev штатно берёт несколько вопросов к тексту. Но LLM тоже можно дать 17 вопросов в одном промпте или отправить 17 запросов параллельно. Проверяем, остаётся ли преимущество при обоих способах. → [02](#)
- **Меньше ложных тревог.** Отдельный бинарный опыт на ContractNLI: есть противоречие или нет. Сравниваем precision при одинаковом recall, чтобы не путать качество с привычкой чаще отвечать «да». → [03](#)
- **Вероятности, которым можно верить.** На тех же бинарных ответах: если модель обещает 80%, противоречие должно встречаться примерно в 80% таких случаев. → [04](#)

Обратите внимание: ContractNLI участвует дважды. В разделе 01 это трёхклассовая задача, где проверяем метку. В разделах 03 и 04 это отдельный бинарный прогон по тем же 510 парам, где проверяем score. Это не одни и те же ответы, схлопнутые в два класса.

01 Где лучше качество

Macro-F1, выше лучше. Каждый класс весит одинаково, поэтому редкие классы не теряются.

ПУБЛИЧНЫЙ ПОДНАБОР	JEV 1.13	DEEPSEEK V4.1 FLASH	QWEN3.8 27B
ANLI · 300 · один вопрос	0.779	0.676	0.661
ContractNLI · 510 · один вопрос	0.734	0.689	0.760
ContractNLI · те же 510 · 17 вопросов за вызов	0.735	0.736	0.582
BANKING77 · 385 · 77 классов	0.773	0.654	0.769

Jev выше на ANLI. На одиночных вопросах к договорам выше Qwen. На BANKING77 Jev и Qwen близки. Общего рейтинга нет: задачи разные, и победитель зависит от задачи.


Два режима на ContractNLI отличаются не только упаковкой вопросов. В одиночном режиме метка LLM берётся из logprobs одного токена, в 17-вопросном — из сгенерированной последовательности кодов. Поэтому рост DeepSeek с 0.689 до 0.736 — наблюдение, а не изолированный эффект группировки. Точно так же равенство 0.734 и 0.735 у Jev не доказывает, что она оценивает вопросы независимо: одинаковая метрика ничего не говорит о механизме. Независимость вопросов остаётся словами поставщика.

Полнота ответов Qwen. В 9 из 30 вызовов с 17 вопросами Qwen вернула не то число кодов; все 17 решений такого вызова засчитаны как ошибки. У Jev и DeepSeek таких сбоев не было. Это слабость нашего формата коротких кодов без схемы, а не доказательство, что Qwen не решает сами вопросы. Исправит ли это JSON Schema и какой ценой, мы не проверяли.

Про полный вектор вероятностей. На BANKING77 сравниваем только метки. Jev отдаёт вероятности всех 77 вариантов сразу; у выбранных LLM top-20 logprobs этот вектор не покрывает, а код класса может состоять из нескольких токенов.

02 Два способа ускорить одну и ту же работу

Работа одна: 51 решение — 17 вопросов к каждому из трёх договоров. Ускорить можно двумя способами. Слева на графике вопросы упакованы в один вызов: 1, 4 или 17 вопросов на запрос, запросы подряд. Справа каждый вопрос — отдельный запрос, а параллельно уходит 1, 4 или 16 запросов. Числа 16 и 17 не связаны: 17 — утверждений в договоре, 16 — просто уровень нагрузки в сетке. По оси Y — время завершения всего набора, точки — медиана трёх повторов, полоски — минимум и максимум.



МОДЕЛЬ	ПО ОДНОМУ, ПОДРЯД · С	ПО 17 В ЗАПРОСЕ · С	ПО ОДНОМУ, 16 ОДНОВРЕМЕННО · С	СТОИМОСТЬ 1000 РЕШЕНИЙ · РЕЖИМ 17 В ЗАПРОСЕ
Jev 1.13	7.75	0.73	1.12	\$0.014
DeepSeek V4.1 Flash	12.01	1.68	4.47 ‡	\$0.026
Qwen3.8 27B	25.85	3.28 †	5.46	\$0.031

Jev быстрее в каждом измеренном режиме. У всех трёх 17 вопросов в одном вызове дали минимальное время: контекст передаётся один раз. Параллельные одиночные запросы тоже помогают, но контекст уходит повторно, и провайдер лишь иногда переиспользует его через cache. Такой параллелизм доступен всем трём API, поэтому нельзя сравнивать многовопросный Jev с последовательными вызовами LLM и весь выигрыш приписывать модели. Это замер на трёх договорах, на другие нагрузки его не переносим.

Стоимость посчитана по сохранённому usage для режима 17 вопросов в запросе с учётом cache; на другие режимы это число не распространяем.


Что именно измерено. Полное время ответа API с одного сервера в США (IP 107.172.73.82), без SSH. Сеть, очереди, cache и вычисления провайдера здесь не разделить, первые соединения включены. LLM в этом опыте отдаёт коды без logprobs, а Jev — вероятности штатно; скорость выдачи полного вектора вероятностей у LLM не измерялась.

Сноски. † Qwen: в режиме 17 вопросов 1 из 9 вызовов вернул неполный набор кодов; время учтено, качество здесь не оценивается — оно в таблице macro-F1. ‡ DeepSeek: в режиме 16 параллельных запросов часть первых попыток получила HTTP 503. Всего по скоростной серии у DeepSeek 4 таких ошибки на 513 вызовов во всех режимах и повторах, у Jev и Qwen 0 на 513. Время первой попытки включено в замер, диагностический повтор исключён.

03 Меньше ложных тревог при нужном recall

Задача — найти противоречие в договоре. Здесь отдельный бинарный опыт: те же 510 пар, тот же вопрос всем трём моделям с двумя вариантами ответа. Противоречий 48 из 510 (9.4%), подтверждённые и неизвестные утверждения — класс «нет противоречия». Модель выдаёт вероятность противоречия; этот score используется и здесь, и в разделе 04.

Recall: сколько настоящих противоречий нашли. **Precision:** какая доля тревог верна. Каждый порог даёт свою точку на кривой; при нужном recall выбираем кривую выше — она даёт меньше ложных тревог.



МОДЕЛЬ	AVERAGE PRECISION ↑	PRECISION ПРИ RECALL 81.25%	ВЕРНЫЕ / ЛОЖНЫЕ ТРЕВОГИ
Jev 1.13	0.713	48.1%	39 / 42
DeepSeek V4.1 Flash	0.677	50.0%	39 / 39
Qwen3.8 27B	0.660	40.6%	39 / 57


Точку recall ≈ 80% мы выбрали как иллюстративный рабочий ориентир, не как требование продукта. На выборке ближайший достижимый шаг у всех трёх — 39 из 48 противоречий, 81.25%, без интерполяции. При другом требуемом recall соотношение кривых меняется, поэтому смотрите на всю кривую, а не только на точку 80%. Порог на тестовой кривой описывает этот тест, а не готовый production-порог.

Average Precision сводит всю кривую в одно число. У Jev оно численно выше на этой выборке, но это не выигрыш в каждой точке.

Насколько это надёжно. Интервалы считали bootstrap-ом по целым договорам. Precision в выбранной точке: DeepSeek - Jev = +1.9 п.п., 95% интервал [-13.2; +14.3]; Qwen - Jev = -7.5 п.п., [-20.9; +13.7]. AP: DeepSeek - Jev = -0.037, [-0.102; +0.025]; Qwen - Jev = -0.053, [-0.120; +0.028]. Все интервалы включают ноль: статистический победитель не установлен ни по AP, ни в выбранной точке. Равенство этим тоже не доказано — выборка просто мала. Что видно без статистики: около выбранного recall у Jev и DeepSeek примерно половина тревог ложная. Удобный API сам по себе проблему качества не решает.

04 Можно ли верить вероятностям

Большое число ещё не значит надёжную вероятность. Здесь те же бинарные score, что и в разделе 03: p – вероятность противоречия, не вероятность того, что модель права. Если модель выдаёт 0.8, среди многих таких случаев противоречие должно встречаться примерно в 80%. На графике диагональ – идеальное совпадение; точка ниже диагонали означает, что модель завышает вероятность противоречия. Числа у точек – размер группы.



Монотонность – отдельное полезное свойство. Чем выше предсказанная вероятность, тем чаще должно встречаться противоречие. Для этого кривая должна в целом расти; для хорошей калибровки – ещё и попадать на диагональ. Поэтому модель может завышать вероятности, но всё же давать полезный сигнал: «здесь риск выше, здесь ниже».

У Jev этот рост визуально ровнее, чем у DeepSeek: начиная с группы 50–60%, фактическая частота последовательно растёт от 10% до 66% в верхней группе. Но строгой монотонности на всём диапазоне нет и у Jev. У Qwen тоже виден общий рост с локальными спадами. Скачки DeepSeek выглядят резче, однако часть точек построена всего по 1–4 примерам: например, 100% в группе 70–80% – это одно противоречие из одного случая. Поэтому более ровная кривая Jev – обнадеживающее наблюдение на этой выборке, а не доказанное преимущество. Она также не заменяет PR-кривую: та проверяет полезность ранжирования без такого разбиения на группы.

Самая уверенная группа, $p \geq 90\%$. Jev: обещано 97.7%, противоречие в 65.9% случаев, 44 примера. DeepSeek: 99.3% → 57.1%, 49 примеров. Обе модели в этой зоне заметно самоуверенны. У Qwen в этом диапазоне один пример – судить не по чему.

МОДЕЛЬ	Brier ↓	ECE ↓
Jev 1.13	0.081	8.8 п.п.
DeepSeek V4.1 Flash	0.075	7.3 п.п.
Qwen3.8 27B	0.050	1.6 п.п.

Brier – среднее $(p - y)^2$, где $y = 1$, если противоречие есть. Ориентир для масштаба: постоянный прогноз 9.4%, то есть частота противоречий в этой же выборке, даёт Brier 0.085. Jev и DeepSeek выигрывают у него немного, Qwen – заметно. Но постоянный прогноз не отличает один случай от другого, поэтому малый Brier не отменяет пользу ранжирования из раздела 03.

ECE – средний разрыв между обещанной вероятностью и реальной частотой по десяти группам, с весом по числу примеров. Редкие группы шумные: у Qwen почти все примеры лежат в нижней группе, и низкий ECE во многом оттуда.

Qwen лучше по Brier и ECE, хотя ниже по AP. Это разные свойства: можно аккуратно оценивать вероятность и при этом давать больше ложных тревог при требуемом recall. Всё это исходные числа моделей без посткалибровки; посткалибровка за рамками отчёта, и мы не обещаем, что она что-то исправит.

05 Что выяснили и чего не доказали

Где преимущество Jev видно

Скорость. Jev была быстрее в каждом проверенном режиме. При 17 вопросах за вызов весь набор из 51 решения занял 0.73 с против 1.68 с у DeepSeek и 3.28 с у Qwen. Это время API-маршрута, а не чистые вычисления модели, и у Qwen один из девяти ответов в этом режиме был неполным.

Полный вектор вероятностей. На 77 классах Jev возвращает вероятности всех вариантов сразу; выбранные LLM с top-20 logprobs этого не дают. Несколько вопросов к тексту у Jev — штатный режим. У LLM в нашем формате коротких кодов без схемы полноту ответа приходится проверять отдельно; проверил бы её JSON Schema, мы не измеряли.

Где общего превосходства нет

Качество зависит от задачи. Jev выше на ANLI, Qwen выше на одиночных вопросах к договорам, на BANKING77 они близки.

Вероятности Jev не лучше автоматически. AP у Jev численно выше, но интервалы включают ноль: победитель по ранжированию не установлен. По совпадению вероятности с реальной частотой лучше Qwen. Уверенные ответы Jev заметно завышены.

Что это значит для «новизны»

Классификация с вероятностями сама по себе не новая возможность: наш простой baseline «LLM + logprobs» работает. Но и списывать Jev на маркетинг нельзя: в этих замерах есть выигрыш по скорости и удобный полный вектор вероятностей. Ни новую архитектуру, ни универсальное превосходство, ни равенство с LLM мы не доказали. Практический выбор — по своей задаче: скорость и удобство отдельно, точность и надёжность вероятностей отдельно.

Есть и практический пробел в LLM API. Приём «один токен + logprobs» требует доступа к вероятностям токенов, а у ряда новых моделей его нет в доступном API. Например, при проверке каталога OpenRouter 1 октября 2026 года у Gemini 3.8 Flash и Claude Sonnet 5.5 параметры logprobs и top_logprobs не заявлены; у выбранных DeepSeek и Qwen они есть. Это ограничение конкретного API, а не способности модели классифицировать.

[Поддерживаемые параметры моделей](#) · [Каталог API](#).

В этом смысле Jev и подобные специализированные модели закрывают реальную потребность: возвращают оценки всех заданных вариантов через интерфейс, прямо предназначенный для классификации и нескольких вопросов к тексту. Не нужно искать подходящую пару модель/провайдер, сопоставлять классы с токенами и проверять, поместились ли они в top-k. Новизна здесь может быть в доступности и удобстве уже знакомой возможности — даже без универсального выигрыша по качеству и без гарантии калиброванных вероятностей.

Границы опыта. Две LLM выбраны по доступности, рабочим logprobs и отключаемому reasoning, а не как самые точные; на все LLM результат не обобщается. Публичные англоязычные поднаборы могли попадать в предобучение. Бинарные вероятности проверены только на ContractNLI: 30 договоров, 48 противоречий; разметку не меняли. Замеры качества Jev и DeepSeek — 21–22 сентября, Qwen — 24 сентября, все скоростные режимы — 24 сентября. Сравниваются доступные API-маршруты, не одинаковое железо.

[Полные метрики и score](#) · [Таблица качества CSV](#) · [Протокол](#) · [Проверка сырых ответов](#). Данные: [ANLI](#), [ContractNLI](#), [BANKING77](#).